Spark 运行机制理解

第一题：Spark 本地模式下有哪些组件，作用分别是什么

在 Spark **本地模式（local mode）** 下，所有组件都运行在**同一个 JVM 进程**中，本质是用多线程模拟分布式环境。下面是核心组件及其作用：

Spark 本地模式核心组件及作用

1. Driver（驱动程序）

   作用：

   是 Spark 应用的入口，负责创建 `SparkContext/SparkSession`。

   解析用户代码，构建 **DAG 有向无环图**。

   调度任务、收集结果、监控整个作业执行。

   本地模式特点：和 Executor 同进程，既是驱动器也是计算节点。

2. Executor（执行器）

   作用：

   负责执行 Driver 分配的 **Task（任务）**。

   管理计算所需的内存（堆内 / 堆外）、缓存 RDD/DataFrame。

   向 Driver 汇报任务状态。

   本地模式特点：

   只有**一个 Executor**，运行在 Driver 同 JVM 中。

   线程数由 `local[N]` 指定：`local[*]` 表示用 CPU 所有核心数。

3. TaskScheduler（任务调度器）

   作用：

   将 DAG 拆分为 Stage，再拆分为 Task。

   负责将 Task 提交给 Executor 执行。

   本地模式实现：`LocalSchedulerBackend`，直接在本地线程池运行任务。

4. DAGScheduler（DAG 调度器）

   作用：

   根据宽依赖（shuffle）切分 Stage，形成 Stage 有向无环图。

   决定任务的执行顺序，处理 Stage 失败重试。

5. SparkContext / SparkSession

   SparkContext：连接 Spark 集群的“总入口”，管理资源、调度、通信。

   SparkSession（Spark 2.x+）：统一入口，整合 SQL、DataFrame、Streaming 等 API。

6. **本地模式特有的组件**

   LocalBackend：本地调度后端，用 Java 线程池模拟分布式任务执行。

   LocalEndpoint：本地通信端点，用于内部 RPC 通信（本地模式简化实现）。

本地模式与集群模式的关键区别

无独立的 **Cluster Manager**（Standalone Master/YARN/Standalone/K8s）。

无独立的 Worker 节点。

Driver 和 Executor 共 JVM，通信开销极小，适合**开发调试、单元测试、小数据量作业**。